

Ocenjevanje fermentacijske aktivnosti z zvokom

Yon Ploj

Povzetek—V članku predstavimo metodo merjenja fermentacijske aktivnosti piva z analizo zvoka mehurčkov, ki nastajajo pri izhajanju ogljikovega dioksida iz vrelna posode. S posnetki zvokov mehurčkov smo naučili model, ki razlikuje mehurčke od ambientnega šuma. Primerjali smo učinkovitost metod globokega učenja (konvolucijsko nevronske mreže in nevronske mreže z dolgotrajno-kratkoročnim spominom) ter ju ovrednotili z ozirom na metodo podpornih vektorjev. Arhitektura LSTM se je v kombinaciji s kratkočasovno Fourierjevo transformacijo izkazala za najbolj učinkovito, saj je po F1 vrednosti dosegla rezultat 0,875.

I. UVOD

Fermentacija ali alkoholno vrenje je osrednji biokemijski proces, pri katerem glive kvasovke pretvarjajo sladkor v uporabno energijo v odsotnosti kisika. Pri reakciji kot stranski produkt nastajata etanol (namizni alkohol) in ogljikov dioksid.



Pri proizvodnji piva (in drugih alkoholnih pijač) spodbujamo fermentacijo kvasovk v nadziranih okoliščinah, saj nam te pretvorijo sladkor iz ječmenovega slada v alkohol.

Hitrost fermentacije odraža metabolno aktivnost kvasa v trenutnih okoljskih pogojih, zato ocenjevanje fermentacijske aktivnosti predstavlja nepogrešljivo povratno informacijo o zdravju kvasa, kar neposredno vpliva na kakovost piva.

Avtomatska ocena hitrosti fermentacije omogoča zgodnje odkrivanje odstopanj od optimalnih pogojev in pravočasno prilagajanje. Avtomatizacija nam omogoča nenehno merjenje, s čimer prispevamo k večji procesni stabilnosti in s tem boljšim in ponovljivejšim senzoričnim lastnostim piva.

Industrijski respirometri ponavadi delujejo na principu volumetrične analize izhajajočega ogljikovega dioksida, zaradi česar potrebujejo natančne in drage merilne instrumente. Brez njih se ponavadi zanašamo na ocenjevanje "po posluhu", torej vsake toliko časa poslušamo nastajanje mehurčkov v sifonu vrelnega zapaha (ang. *airlock*).


V tem članku predstavimo pristop ocenjevanja fermentacijske aktivnosti piva z analizo zvoka mehurčkov, kar omogoča neinvazivno in avtomatizirano spremljanje fermentacije.

II. METODE


Našo eksperimentalno postavitev (slika 1) obsega 30-litrska neprodušno zaprta (razen vehe) fermentacijska posoda, v njejnem pokrovu pa vrelna veha, ki omogoča izhajanje plinov, ko v posodi naraste tlak. Na pokrovu posode se nahaja mikro-krmilnik ESP-32D z mikrofonom INMP441, ki komunicira z računalnikom prek brezžične povezave.

A. Zajem podatkov

V prvem delu smo iz mikrokrmilnika zbirali surove zvočne posnetke. Zbrali smo posnetke v različnih reprezentativnih okoliščinah, ki jih pričakujemo v praksi. Ker se fermentor nahaja v bivalnem prostoru, pričakujemo šume, kot so pogovor, smrčanje, zvok televizije, ipd.



Slika 1. Eksperimentalna postavitev: vrelna posoda z veho in mikro-krmilnikom



Slika 2. Primer oznak na posnetku z močnim šumom

Poleg šumnih posnetkov smo zbrali tudi večjo količino posnetkov mehurčkov v tišini, saj je slednje lažje označevati avtomatsko.


S protokolom WebSocket smo v živo pošiljali zvok na strežnik, ki je posnetek shranil v datoteko oblike wav.

B. Označevanje

Šumne posnetke smo ročno opremili z oznakami s pomočjo odprtokodnega programa Label Studio. Zvoke mehurčkov smo označili kot časovne intervale na posnetku.

Slika 2 prikazuje enega izmed težavnejših primerov, v katerem je v ozadju prisoten pogovor in zvok televizije.

Zaradi težavnosti označevanja smo ročno označili le posnetke s šumom. Te nam bodo služili kot validacijska množica, saj predstavljajo resnično obnašanje modela v praksi. Za potrebe



Slika 3. Primer oznak na posnetku v tišini

Tabela I
UPORABLJENI PARAMETRI MODELOV

Metoda	Parametri
STFT	Hannovo okno 2048, korak 512
SVM	jedro RBF, $C = 1$
Naklj. gozd	100 dreves, globina 10
CNN	kanali (16, 32, 64), jedro 3, dropout 0,25
LSTM	2 plasti, 64 skritih enot, dropout 0,25
Učenje NN	Adam, $\eta = 10^{-3}$, batch 32, 20 epoh

učenja smo zbrali večjo količino tihih posnetkov (primer na sliki 3), na katerih smo za mehurčke označili intervale, kjer glasnost preseže določen prag. Tem posnetkom bomo naknadno dodali umeten šum.

Validacijsko množico sestavlja 130 označenih intervalov na skupnem obsegu 256 sekund posnetka, učno množico pa čez 10.617 intervalov na skupno 8h posnetka.

C. Gradnja detektorja

S programskim jezikom Python smo zgradili orodje, ki omogoča testiranje in evalvacijo različnih detektorjev in metod predprocesiranja.

1) *Vzorčenje*: Iz zvočnih posnetkov smo vzorčili okna v širini 0,10 sekunde. Vzorčili smo le okna, ki so bodisi popolnoma vsebovana v označbi mehurčka, bodisi z njimi nimajo preseka.

Pri validacijski množici smo vzorčili kar se da mnogo pozitivnih vzorcev, dokler je bilo to še mogoče brez prekrivanja. Zaradi stohastične narave vzorčenja število vzorcev ni bilo konstantno, temveč se je gibalo med 150 in 165. Pri negativnih vzorcih ni bilo omejitev, a smo jih vedno zajeli le toliko, kolikor je bilo pozitivnih. V nasprotnem primeru smo sicer opazili, da so se nekateri klasifikatorji naučili napovedovati le prevladujoči razred.

2) *Algoritmi*: Implementirali smo metodo podpornih vektorjev (SVM), naključni gozd, konvolucijsko nevronske mreže (CNN) in nevronske mreže z dolgotrajno-kratkoročnim spominom (LSTM).


Podatke smo predpripravili bodisi z identitetno funkcijo (brez predprocesiranja) bodisi s kratko-časovno Fourierjevo transformacijo (STFT).

Zaradi počasnosti učenja modela LSTM na dolgi časovni vrsti smo v primeru identitetnega predprocesorja pri tem modelu morali vzorčiti podmnožico podatkov (v našem primeru le 5%).

Ključni parametri uporabljenih metod so na kratko povzeti v tabeli I. Določili smo jih z nesistematičnim informiranim ugibanjem na validacijski množici.

III. REZULTATI

Tabela II prikazuje glavne rezultate analize – natančnost, priklic in F1 vrednosti različnih kombinacij detektorjev in



Slika 4. Rezultati zmagovalnega detektorja na močno šumnem posnetku

predprocesorjev. Očitno je kombinacija modela LSTM in kratkočasovne Fourierjeve transformacije najboljša.

Konvolucijska mreža ima primerljivo učinkovitost kot LSTM, a je zaradi večjega števila učilnih parametrov manj privlačna za praktično uporabo.

Zaradi omejenega vzorčenja rezultat LSTM brez predprocesiranja ne dosega omembe vrednih rezultatov.

Tudi manj računsko zahtevne metode, na primer metoda podpornih vektorjev, so se v dani nalogi izkazale za precej učinkovite.

Slika 4 prikazuje vizualen rezultat najboljšega detektorja. Vidimo, da kljub močnemu šumu dobro loči med zvokom mehurčka in človeškega glasu.

Tabela II
UČINKOVITOST RAZLIČNIH KOMBINACIJ PREDPROCESORJEV IN DETEKTORJEV

Detektor	Predproc.	Natančnost	Priklic	F1
SVM	Identiteta	0,756	0,689	0,721
	STFT	0,860	0,822	0,841
Naklj. gozd	Identiteta	0,692	0,800	0,742
	STFT	0,868	0,733	0,795
LSTM	Identiteta	0,512	0,478	0,494
	STFT	0,824	0,933	0,875
CNN	Identiteta	0,741	0,889	0,808
	STFT	0,838	0,689	0,756

IV. DISKUSIJA

Rezultati so jasno pokazali, da metode globokega učenja prekašajo klasične metode strojnega učenja pri danem problemu, vendar razlika ni znatna.

Omembe vredno je, da klasične metode za delovanje potrebujejo manj računskih virov, s čimer omogočajo poganjanje modela kar na mikrokrmilniku samem. S tako rabo pripomoremo k odgovornemu ravnanju z občutljivimi podatki, saj lokalna obdelava zmanjšuje izpostavljenost podatkov med prenosom ali obdelavo. To je potencialno pomemben dejavnik pri uvajanju rešitve v pivovarski industriji, kjer lahko uporabniki izražajo zadržke glede pošiljanja zvoka iz poslovnih prostorov na infrastrukturo zunanega ponudnika.

V prihodnje bi bilo smiselno raziskati še druge načine za zmanjšanje računske zahtevnosti detekcije mehurčkov brez izgube natančnosti.

V. ZAKLJUČEK

V tem delu smo predstavili neinvaziven pristop za akustično zaznavanje fermentacijske aktivnosti piva z analizo zvoka me-

hurčkov v vrelni vehi. Pokazali smo, da je mogoče z relativno preprostimi metodami strojnega učenja in ustreznim predprocesiranjem doseči detekcijo tudi v prisotnosti okoljskega šuma.

Eksperimentalni rezultati potrjujejo, da spektralni opis zvoka v kombinaciji s klasifikatorjem podpornih vektorjev omogoča zanesljivo razlikovanje med mehurčki in drugimi zvočnimi dogodki, z metodami globokega učenja pa lahko učinkovitost še bolj izboljšamo.

Predlagana metoda predstavlja cenovno ugodno alternativo klasičnim meritvam fermentacijske aktivnosti ter odpira možnosti za nenehno spremljanje procesa v domačih in manjših komercialnih pivovarskih okoljih.